

TAC-UFLD: pilotos de detecção temporal de faixas

Autores: Tiago Rodrigues, Eva Laussac, Everton Gomedes · UTFPR, Cornélio Procópio, Brasil

Um detector de faixas leve que também olha os quadros anteriores consegue superar a UFLD baseline, que usa um único quadro? A UFLD (ResNet-18) e uma CNN pequena, cada uma com variantes temporais, foram treinadas na base ELAS de faixas do próprio veículo e testadas em três cenas de estrada nunca usadas no treino nem na seleção de modelos.

base ELAS

11 modelos

2 sementes

cenas de teste BR_S02 · VIX_S05 · VV_S03

NVIDIA GeForce RTX 3050

tempo de GPU 4 h 47 min

piloto indicativo, não o protocolo completo

Onde a pesquisa está

Pergunta: um detector de faixas leve que também olha os quadros anteriores consegue superar a UFLD baseline de um quadro e rodar em um sistema embarcado no carro? Tudo abaixo vem de execuções piloto no ELAS (2–3 sementes, treino curto, sem busca de hiperparâmetros); por isso indica direções, não conclusões finais.

OVERFITTING CORRIGIDO

0,07 → 0,86

UFLD baseline, lane F1 no teste: aumento de dados original × com aumento geométrico (3 sementes)

QUADROS LIMPOS

0,881 vs 0,895

UFLD baseline × melhor modelo temporal (UFLD v0.7 ConvGRU): dentro do ruído entre sementes (2 sementes)

QUADRO ATUAL OCLUÍDO

0,761 → 0,875

UFLD baseline × UFLD v0.3 gated com o quadro atual ocluído e os anteriores limpos: +0,114, em todas as sementes

FILTRO DE KALMAN NA SAÍDA

-21 % de jitter


em todos os modelos, sem mudar o lane F1: a referência temporal barata que um modelo aprendido precisa superar

MODELO LEVE

0,850 · 2,8 M


Lane F1 e parâmetros do lite v0.5, contra 0,881 com 21,8 M da UFLD baseline (8× menos parâmetros)

1 • Overfitting: o que resolveu




UFLD baseline treinada com cada receita (mesma divisão, sementes e épocas); lane F1 no teste. O aumento geométrico (deslocamento, zoom, rotação, perspectiva) resolve; espelhamento e regularização forte não.

2 • Onde o tempo ajuda: quadro atual ocluído




Lane F1 no teste com quadros limpos (vazado) e com o quadro atual coberto por retângulos enquanto os anteriores ficam limpos (cheio); o número é o F1 com oclusão e sua variação. Modelos de um quadro só veem a imagem danificada.

3 • Acurácia versus tamanho



Lane F1 no teste (quadros limpos) e parâmetros. Computação por quadro: UFLD 7,1 GMAC, lite 2,0 GMAC; um modelo temporal com features em cache acrescenta só a sua fusão (caso contrário, recalcula 3 quadros). Modelos lite da execução elas_lite_long (treino mais longo).

4 • Até onde olhar para trás (UFLD v0.4 coord)



Lane F1 no teste da UFLD v0.4 coord menos a UFLD baseline para cada comprimento e espaçamento do histórico (quadro k do histórico = $t - k \cdot \text{passo}$; mesma divisão e baseline em todos os braços). O espaçamento muda pouco; cinco quadros são piores que três.

Desafios

- **Base de dados pequena.** O protocolo usa 10 cenas do ELAS, e só 3 ficam reservadas para teste. A UFLD decorava a posição das faixas até entrar o aumento de dados geométrico.
- **Quadros limpos escondem o efeito temporal.** Com quadros limpos, os modelos temporais UFLD ficam a cerca de $\pm 0,02$ de lane F1 da baseline. Duas sementes não bastam para separar isso do ruído.
- **Os modelos leves treinam devagar e de forma instável.** Treinados do zero, precisam de 16 épocas ou mais. O lite v0.5 sem histórico real (o controle de capacidade) marcou 0,877 em uma semente e 0,627 na outra. Com quadros limpos, ainda não se sabe quanto do ganho vem dos quadros anteriores; com o quadro atual ocluído, o histórico vale +0,17 e +0,38 nas duas sementes.
- **Memória em sequências longas.** Os modelos recorrentes derivam quando o estado é mantido ao longo de uma cena inteira (lite v0.6: -0,48 de lane F1). Eles foram treinados só com clipes de 3 quadros.
- **Mais histórico não é melhor.** Espaçar os quadros do histórico de 2, 5 ou 10 quadros não muda nada; usar 5 quadros em vez de 3 reduz o lane F1.
- **Uma única base de dados até agora.** CULane, TuSimple e OpenLane ainda não foram baixadas. Os leitores estão prontos e foram testados em cópias sintéticas da estrutura delas.
- **Ainda sem medição embarcada.** Os números da Jetson são simulações com fatores de lentidão assumidos, não medições.

Próximos passos

1. Rodar o protocolo completo no ELAS: 6 sementes, até 50 épocas e o mesmo orçamento de busca de hiperparâmetros para todos os modelos (cerca de 4–5 dias na RTX 3050).
2. Tornar a robustez um resultado principal: primeiro as corrupções sintéticas, depois oclusões naturais, noite e chuva.
3. Baixar CULane e TuSimple (o guia de download está pronto), pré-treinar nelas, ajustar no ELAS e reportar as métricas oficiais delas.
4. Resolver a questão dos modelos leves: mais sementes e treino mais longo para o lite v0.5 contra seu controle de capacidade, e treinar os modelos recorrentes com sequências longas.
5. Última fase, embarcado: exportar o melhor modelo temporal leve para TensorRT (FP16/INT8) e medir latência, memória e consumo de energia em uma Jetson.

Qual modelo comparar com a baseline

Lane F1 nas cenas de teste nunca vistas, média de 2 sementes; o quadro atual ocluído vem da avaliação de robustez (o histórico continua limpo). Resultados de piloto: indicam a direção, não provam. Modelos lite: execução `elas_lite_long` (treino mais longo).

SITUAÇÃO	SUPERA A BASELINE?	MELHOR MODELO	NÚMEROS
Quadros limpos	Não claramente	nenhum ainda	UFLD v0.7 ConvGRU: +0,014 (0,895 × 0,881); sem o histórico perde só 0,005, então o ganho não é temporal
Quadro atual ocluído (histórico limpo)	Sim, em todas as sementes	UFLD v0.3 gated	UFLD v0.3 gated +0,114, UFLD v0.6 aligned +0,104, UFLD v0.7 ConvGRU +0,041 (baseline 0,761; controle com o mesmo treino 0,742)
Quadro atual borrado, escuro ou com ruído	Não	nenhum	todas as diferenças entre -0,010 e +0,024
Cena de teste com oclusões reais	Sim, mas é uma única cena	UFLD v0.7 ConvGRU	UFLD v0.7 ConvGRU 0,791 × baseline 0,741; +CT 0,772
Estabilidade (jitter)	Não por um modelo aprendido	filtro de Kalman na saída	baseline 1,51 px → 1,19 px com Kalman (−22 %); modelos temporais 1,45–1,75 px
Modelo leve para embarcado (× UFLD baseline)	Sob oclusão sim; em quadros limpos não	Lite v0.5 warped	limpos -0,031, ocluídos +0,068, 8× menos parâmetros (2,8 M × 21,8 M); treinos diferentes: até 16 × 4 épocas
O modelo leve usa o histórico? (× mesmas camadas sem histórico, com oclusão)	Sim, em todas as sementes	Lite v0.5 warped	0,829 × 0,554 (por semente +0,170 / +0,379)

Recomendação

- Comparação principal: UFLD v0.3 (gated) × UFLD baseline.** Mesma rede e mesmo treino, com praticamente nenhum parâmetro a mais; qualquer diferença vem do uso dos quadros anteriores. É o modelo que mais mantém as faixas quando o quadro atual está ocluído, e empata com a baseline em quadros limpos.
- Comparação secundária, para o embarcado: lite v0.5 × UFLD baseline, e lite v0.5 × o mesmo modelo sem histórico.** Mostra o custo de um modelo muito menor e, pelo controle sem histórico, que a robustez vem do tempo.
- Declarar antes da execução completa.** Esta escolha foi feita olhando o teste; para a afirmação ser válida, declare agora as comparações principais e a métrica com oclusão como métrica principal, e use as 6 sementes da execução completa para confirmar ou rejeitar.
- Condição para comparar as famílias:** treinar UFLD e lite com o mesmo protocolo (mesmas épocas máximas e busca de hiperparâmetros) antes de colocar os dois lado a lado num artigo.

Os candidatos lado a lado

MODELO	F1 LIMPOS	F1 OCLUÍDOS	Δ OCLUSÃO × BASELINE	PARÂMETROS (M)	PERDA SEM HISTÓRICO	NOTA
■ UFLD baseline	0,881	0,761	—	21,8	—	referência de um quadro
■ UFLD baseline +CT	0,883	0,742	-0,018	21,8	—	controle: o mesmo treino extra dos modelos temporais, sem histórico
■ UFLD v0.2 weighted	0,872	0,756	-0,005	21,8	0,001	sem ganho com oclusão
■ UFLD v0.3 gated	0,883	0,875	+0,114	21,9	0,012	recomendado: robusto à oclusão, quase sem custo extra
■ UFLD v0.4 coord	0,880	0,765	+0,004	21,8	0,003	sem ganho com oclusão; escolhido na validação limpa para a ablação de histórico
■ UFLD v0.6 aligned	0,880	0,864	+0,104	23,5	0,008	quase tão robusto quanto a v0.3, porém maior e mais complexo

MODELO	F1 LIMPOS	F1 OCUÍDOS	Δ OCLUSÃO × BASELINE	PARÂMETROS (M)	PERDA SEM HISTÓRICO	NOTA
■ UFLD v0.7 ConvGRU	0,895	0,802	+0,041	22,1	0,005	melhor em quadros limpos, mas o ganho não é temporal; o estado deriva em sequências longas
■ Lite baseline	0,322	0,254	-0,507	2,5	—	referência leve de um quadro
■ Lite baseline +CT	0,322	0,258	-0,503	2,5	—	controle de treino da família lite
■ Lite v0.5 warped	0,850	0,829	+0,068	2,8	0,004	candidato embarcado: usa o histórico sob oclusão
■ Lite v0.5 static	0,752	0,554	-0,206	2,8	—	controle de capacidade: mesmas camadas, sem histórico; instável
■ Lite v0.6 ConvGRU	0,561	0,554	-0,206	2,7	0,009	recorrente leve; ainda fraco

“Perda sem histórico”: quanto o lane F1 cai quando o histórico é trocado pelo quadro atual no teste (quadros limpos).


O que os resultados mostram

- **O aumento de dados geométrico elimina o overfitting da UFLD.** Na ablação de aumento de dados (UFLD baseline, 3 sementes, mesma divisão e mesmo orçamento), pequenos deslocamentos, zooms, rotações e mudanças de perspectiva aleatórios, aplicados ao clipe inteiro, elevam o melhor lane F1 de validação de 0,161 para 0,772 e o lane F1 nas cenas de teste nunca vistas de 0,068 para 0,858. A melhor época passa da 1 para a 4, a última. Só as mudanças fotométricas chegam a 0,150 no teste; o espelhamento não acrescenta nada (0,769). A receita do segundo piloto foi escolhida na validação: aumento geométrico mais degradação do quadro atual, para todos os modelos.
- **Dropout + label smoothing + weight decay juntos pioram a UFLD** (0,002 no teste). As faixas continuam sendo previstas em todos os quadros, mas no lugar errado. A causa provável é o label smoothing: ele achata a distribuição sobre as 100 células da grade e puxa o soft-argmax para o centro da imagem. Como o braço muda três coisas ao mesmo tempo, isto é uma hipótese.
- **Nenhum outro remédio isolado resolve o overfitting.** Outros cinco braços da mesma ablação mudam uma única coisa na receita original (3 sementes): taxa de aprendizado do backbone 10× menor (lane F1 no teste 0,050), stem e primeiro estágio da ResNet congelados (0,083), degradação do quadro atual (0,094), oito cenas de treino a mais (0,129) e uma cabeça de 256 unidades em vez de 2048 (0,211). Todos continuam com o melhor resultado na época 1 ou 2. Só o aumento de dados geométrico (0,858) elimina o problema, e por isso ele continua sendo a receita de todos os modelos.
- **Com a nova receita, a UFLD baseline chega a 0,881 de lane F1 no teste** (0,849 nas cenas já vistas), contra 0,057 no primeiro piloto. O segundo piloto treinou 11 modelos × 2 sementes em 4 h 47 min na RTX 3050.
- **Os modelos temporais UFLD empatam com a baseline, mas não a superam com clareza.** A v0.2, a v0.3, a v0.4 e a v0.6 ficam entre 0,872 e 0,883; o controle com o mesmo treino extra fica em 0,883. A UFLD v0.7 (ConvGRU) é a mais alta, com 0,895 (+0,014 sobre a baseline, +0,012 sobre o controle). Porém, trocar o histórico dela pelo quadro atual no teste custa só 0,005, então esse ganho não é claramente temporal.
- **Os modelos lite ficam subtreinados após 4 épocas da nova receita** (eles treinam do zero): lite baseline 0,218, +CT 0,312. O lite v0.5 chega a 0,700 e o lite v0.6 a 0,541, bem acima de ambos, mas trocar o histórico pelo quadro atual custa só 0,020 e 0,017. A maior parte da vantagem vem, portanto, das camadas extras de fusão, e não do tempo.
- **Com 16 épocas, a família lite se aproxima da UFLD com 8× menos parâmetros.** A execução lite mais longa (elas_lite_long, 2 sementes, parada antecipada) leva o lite v0.5 a 0,850 de lane F1 no teste (0,844 / 0,856) com 2,8 M de parâmetros, contra 0,881 da UFLD baseline com 21,8 M. O lite baseline fica em 0,322, e mais treino não o ajuda (+CT 0,322). O controle de capacidade (lite v0.5 com o quadro atual em todas as posições, as mesmas camadas) é instável: 0,877 na semente 1 e 0,627 na semente 2. Por isso, com quadros limpos, quanto do ganho do lite v0.5 vem dos quadros anteriores ainda está em aberto (+0,098 em média; -0,033 e +0,229 por semente). O lite v0.6 (ConvGRU) chega a 0,561.
- **O filtro de Kalman dá a suavidade de graça.** Em todos os modelos, ele reduz o jitter (a oscilação da posição prevista entre quadros) em cerca de 20 % (UFLD baseline: de 1,51 para 1,19 px) sem alterar o lane F1. Os modelos temporais UFLD aprendidos oscilam tanto quanto a baseline (1,45 a 1,75 px contra 1,51 px); portanto, é o filtro, e não a fusão, que deixa a saída mais suave.
- **Manter o estado recorrente ao longo de uma cena inteira ainda não funciona.** Treinada com clipes de 3 quadros, a ConvGRU deriva quando o estado nunca é reiniciado: a UFLD v0.7 perde 0,028 e o lite v0.6 perde 0,483 de lane F1 nesse modo. Para usar um único estado contínuo no carro, é preciso antes treinar com sequências longas (retropropagação truncada no tempo).
- **A oclusão é onde o tempo pode ajudar.** Na única cena de teste marcada como "oclusão" (VIX_S05), a UFLD v0.7 marca 0,792, contra 0,741 da baseline e 0,772 do controle com o mesmo treino extra; nas outras duas cenas a baseline é a melhor (0,948). Uma única cena é anedótica.

- **Quando o quadro atual está ocluído, os modelos temporais mantêm as faixas.** A avaliação de robustez (`python -m tac_ufld robustness`) reavaliou todos os checkpoints nos 2,610 quadros de teste. Em cada quadro, a imagem atual foi coberta por retângulos, borrada, escurecida ou recebeu ruído, enquanto os quadros do histórico ficaram limpos; todos os modelos viram as mesmas corrupções. Com oclusão (673 quadros), a UFLD v0.3 mantém 0,875 de lane F1 (sementes 0,865 / 0,886) e a v0.6 0,864 (0,857 / 0,871), contra 0,761 da baseline (0,753 / 0,768) e 0,742 do controle com o mesmo treino extra. São +0,11 nas duas sementes; mais treino, sozinho, não fecha a diferença. Em todos os quadros degradados, a v0.3 chega a 0,886 e a v0.6 a 0,884, contra 0,850 da baseline; para a v0.3 e a v0.6, isso fica levemente acima do F1 com quadros limpos (0,883 e 0,880). Desfoque, escurecimento e ruído quase não afetam nenhum modelo UFLD (dentro de $\pm 0,03$). A v0.7 ganha menos com oclusão (0,802), e os modelos lite perdem de 0,02 a 0,07, como suas baselines. O filtro de Kalman não acrescenta nada aqui. Ressalvas: 2 sementes, um único conjunto fixo de corrupções sintéticas, e os modelos foram treinados com degradação do quadro atual; então isto mede o que esse treino ensina, e não oclusões naturais.
- **Com o quadro atual ocluído, o modelo lite claramente usa o histórico.** Na avaliação de robustez da execução lite longa, o lite v0.5 mantém 0,829 de lane F1 com oclusão (sementes 0,817 / 0,840, só 0,02 abaixo do valor com quadros limpos). O controle de capacidade, com as mesmas camadas mas o quadro atual em todas as posições, cai para 0,554 (0,648 / 0,461). São +0,17 e +0,38 a favor do histórico real, nas duas sementes. O lite baseline fica perto de 0,25 e o lite v0.6 perto de 0,55. Mesmas ressalvas da UFLD: 2 sementes, oclusões sintéticas.
- **Olhar mais para trás não ajuda; olhar mais quadros atrapalha.** A ablação de histórico (`ablation_history`, UFLD v0.4, o modelo temporal escolhido na validação do piloto 2, 2 sementes) usa sua própria divisão, com blocos de 180 quadros, na qual a baseline marca 0,831. A v0.4 ganha +0,029 sobre a baseline com 3 quadros espaçados de 2, +0,028 espaçados de 5 e +0,027 espaçados de 10, mas só +0,004 com 5 quadros espaçados de 5. O espaçamento do histórico quase não importa nessa faixa; uma janela mais longa piora a v0.4.
- **Custo.** Com as features do histórico em cache, cada modelo temporal UFLD custa o mesmo que sua baseline (7,1 GMACs por quadro) mais a fusão. Por clipe de 3 quadros, a v0.7 precisa de 21,5 GMACs e 22,1 M de parâmetros (+0,3 M), e a v0.6 de 21,8 GMACs e 23,5 M (+1,7 M). Os modelos lite precisam de 2,0 GMACs por quadro e de 2,5 a 2,8 M de parâmetros.

Os modelos

Duas famílias, cada uma com uma baseline de um quadro e variantes temporais construídas sobre ela. Todos leem o quadro atual e preveem as duas faixas do veículo nesse quadro; os temporais também leem quadros anteriores.



- Todo modelo temporal mantém o backbone e a cabeça da sua baseline e só acrescenta uma etapa de fusão entre eles. Ele é comparado com a própria baseline nas mesmas sementes.
- Três perguntas separam os modelos temporais: alinham os quadros antes de fundir (v0.5, v0.6)? Como lembram (janela fixa de 3 quadros da v0.2 à v0.6, estado recorrente na v0.7 e no lite v0.6)? Quanto custam (UFLD cerca de 7 GMACs por quadro, lite cerca de 2)?
- Com as features em cache, cada quadro é codificado uma vez; assim, um modelo temporal custa a sua baseline mais a etapa de fusão, e não três backbones.
- Os controles não são candidatos. O +CT separa o ganho temporal do treino extra, o lite v0.5 static o separa das camadas extras de fusão, e o filtro de Kalman mostra o que uma simples filtragem da saída já oferece.

MODELO	PAPEL	QUADROS USADOS	COMO O HISTÓRICO ENTRA	ALINHA O MOVIMENTO	MEMÓRIA	PARÂMETROS (M)
■ FAMÍLIA UFLD (RESNET-18, IMAGENET)						
UFLD baseline	baseline	t	nenhum	não	nenhum	21,78
UFLD baseline +CT	controle	t	nenhum	não	nenhum	21,78
UFLD v0.2 weighted	temporal	t-4, t-2, t	média ponderada	não	janela de 3 quadros	21,78
UFLD v0.3 gated	temporal	t-4, t-2, t	gates por célula	não	janela de 3 quadros	21,91
UFLD v0.4 coord	temporal	t-4, t-2, t	média ponderada	não	janela de 3 quadros	21,78
UFLD v0.6 aligned	temporal	t-4, t-2, t	warp + gate	sim (fluxo aprendido)	janela de 3 quadros	23,50
UFLD v0.7 ConvGRU	temporal	t-4, t-2, t	ConvGRU	não	estado recorrente	22,07
■ FAMÍLIA LITE (CNN DE 4 BLOCOS, TREINADA DO ZERO)						
Lite baseline	baseline	t	nenhum	não	nenhum	2,49
Lite baseline +CT	controle	t	nenhum	não	nenhum	2,49
Lite v0.5 warped	temporal	t-4, t-2, t	warp + gate	sim (fluxo aprendido)	janela de 3 quadros	2,84
Lite v0.6 ConvGRU	temporal	t-4, t-2, t	ConvGRU	não	estado recorrente	2,73

■ FAMÍLIA UFLD

■ **UFLD baseline** baseline UFLD oficial (Qin et al., ECCV 2020), notebook do orientador 21,78 M parâmetros · 7,1 GMACs por clipe

O QUE FAZ

Ultra-Fast Lane Detection com uma ResNet-18 pré-treinada no ImageNet. A detecção de faixas é uma classificação por linha: para cada uma das 18 linhas da imagem e cada posição de faixa, a cabeça escolhe uma de 100 células horizontais, ou "sem faixa". Um quadro de entrada, sem memória.

DIFERENÇA

A referência da família UFLD. Todo modelo temporal UFLD parte dos pesos treinados dela e é comparado com ela nas mesmas sementes.

■ **UFLD baseline +CT** controle controle da v0.4 21,78 M parâmetros · 7,1 GMACs por clipe

O QUE FAZ

A mesma rede treinada uma segunda vez a partir do seu melhor checkpoint, exatamente com o cronograma que as variantes temporais recebem após a inicialização.

DIFERENÇA

Um controle, não um candidato. Um modelo temporal que supera a baseline mas não este controle ganhou pelo treino extra, não pelo tempo.

■ **UFLD v0.2 weighted** temporal Notebook do orientador 21,78 M parâmetros · 21,3 GMACs por clipe, 3 quadros por clipe

O QUE FAZ

Codifica os três quadros com a ResNet compartilhada e faz a média dos mapas de features com três pesos aprendidos (começando em 0,1 / 0,2 / 0,7) antes da cabeça da UFLD. Treinado com uma perda extra de existência e uma perda de consistência temporal.

DIFERENÇA

A fusão mais simples: um peso por quadro, o mesmo em todos os pixels. Marcações que se moveram entre os quadros são somadas em posições diferentes.

■ **UFLD v0.3 gated** temporal Notebook do orientador 21,91 M parâmetros · 21,4 GMACs por clipe, 3 quadros por clipe

O QUE FAZ

Como a v0.2, mas uma pequena rede convolucional prevê um gate softmax por quadro e por célula de features, com viés para o quadro atual.

DIFERENÇA

Pode usar o histórico só onde o quadro atual é fraco, como numa célula ocluída. Como a v0.2, funde mapas de features não alinhados.

■ **UFLD v0.4 coord** temporal Notebook do orientador 21,78 M parâmetros · 21,3 GMACs por clipe, 3 quadros por clipe

O QUE FAZ

A rede da v0.2 com outra perda: um termo de coordenada via softmax penaliza o erro de posição da faixa em pixels, e a perda de existência é reponderada.

DIFERENÇA

A mesma fusão da v0.2. Testa se uma perda que considera a posição ajuda; a rede em si não muda.

■ **UFLD v0.6 aligned** temporal Novo na v0.4 (adaptado do lite v0.5) 23,50 M parâmetros · 21,8 GMACs por clipe, 3 quadros por clipe

O QUE FAZ

Um campo de fluxo aprendido (até 4 células da grade de features 12x16, cerca de 128 px) desloca cada mapa do histórico sobre o quadro atual. O histórico alinhado é comprimido e misturado por um gate por célula que começa quase fechado.

DIFERENÇA

O único modelo UFLD que alinha os quadros antes de fundir, para que marcações em movimento não fiquem borradas. Acrescenta cerca de 1,7 M de parâmetros à baseline.

■ **UFLD v0.7 ConvGRU** temporal Novo na v0.4 22,07 M parâmetros · 21,5 GMACs por clipe, 3 quadros por clipe

O QUE FAZ

Uma GRU convolucional (64 canais) percorre os mapas de features reduzidos do quadro mais antigo ao atual. O estado final é projetado de volta e somado às features atuais. A projeção começa em zero, então o modelo não treinado é exatamente a baseline.

DIFERENÇA

Lembra por meio de uma recorrência com gates em vez de uma soma ponderada. Em produção, pode manter um estado por câmera em vez de guardar mapas de features anteriores.

■ FAMÍLIA LITE

■ **Lite baseline** baseline Script de desenvolvimento do ELAS 2,49 M parâmetros · 2,0 GMACs por clipe

O QUE FAZ

Uma CNN pequena: quatro blocos convolucionais com stride 2 (32 a 128 canais) e uma cabeça que reduz as features para a grade 18x100 de âncoras de linha e classifica cada linha com um MLP compartilhado. Treinada do zero, sem ImageNet.

DIFERENÇA

A referência da família lite: cerca de 8 vezes menos parâmetros e 3 a 4 vezes menos computação que a UFLD.

■ Lite baseline +CT

controle

controle da v0.4

2,49 M parâmetros · 2,0 GMACs por clipe

O QUE FAZ

A lite baseline treinada uma segunda vez a partir do seu melhor checkpoint, com o cronograma das variantes temporais.

DIFERENÇA

O controle com o mesmo treino para o lite v0.5 e o lite v0.6.

■ Lite v0.5 warped

temporal

Script de desenvolvimento do ELAS (refatorado)

2,84 M parâmetros · 6,0 GMACs por clipe, 3 quadros por clipe

O QUE FAZ

A lite baseline com fusão residual alinhada: um fluxo aprendido (até 8 células com stride 16, cerca de 128 px) alinha cada mapa de features do histórico ao atual, e um gate por pixel que começa fechado mistura o histórico alinhado.

DIFERENÇA

A mesma ideia de fusão da UFLD v0.6 numa rede 8 vezes menor.

■ Lite v0.6 ConvGRU

temporal

Novo na v0.4

2,73 M parâmetros · 6,1 GMACs por clipe, 3 quadros por clipe

O QUE FAZ

A lite baseline com a fusão ConvGRU da UFLD v0.7 (64 canais ocultos, saída começando em zero).

DIFERENÇA


Memória recorrente na menor rede: a candidata para um sistema embarcado que mantém um tensor de estado por câmera. Ao contrário da v0.5, não alinha os quadros explicitamente.

Referência, não um modelo: Qualquer modelo + filtro de Kalman: um filtro de Kalman causal de velocidade constante em cada ponto de faixa, com suavização da existência, ajustado na validação. Custa microssegundos por quadro e é o patamar que um modelo temporal aprendido precisa superar.


Lane F1 em estradas nunca vistas

Lane F1 no estilo CULane: cada faixa desenhada com 12 px de largura (30 px em 1640 px, escalado para 640 px), pareamento um a um, correta quando IoU $\geq 0,5$. Pós-processamento ajustado só na validação. No ELAS todo modelo prevê as duas faixas do veículo em todo quadro, então precisão = revocação = F1: os erros são faixas mal posicionadas, não faixas perdidas.

Cenas de teste (estradas nunca vistas)



Blocos de teste de cenas já vistas



Cenas de teste, todas as métricas (média ± desvio padrão entre sementes)

MODELO	LANE F1 @0,5	LANE F1 @0,35	F1 DE PIXEL	F1 DE ÂNCORA	JITTER (PX)	FP	FN
■ UFLD baseline	0,881 ± 0,001	0,962 ± 0,008	0,812 ± 0,004	0,951 ± 0,001	1,51 ± 0,01	622 ± 4	622 ± 4
■ UFLD baseline +CT	0,883 ± 0,005	0,963 ± 0,004	0,809 ± 0,001	0,949 ± 0,001	1,81 ± 0,00	610 ± 27	610 ± 27
■ UFLD v0.2 weighted	0,872 ± 0,007	0,954 ± 0,010	0,806 ± 0,007	0,948 ± 0,003	1,45 ± 0,02	670 ± 37	670 ± 37
■ UFLD v0.3 gated	0,883 ± 0,015	0,958 ± 0,005	0,814 ± 0,008	0,950 ± 0,001	1,58 ± 0,04	608 ± 77	608 ± 77
■ UFLD v0.4 coord	0,880 ± 0,023	0,954 ± 0,014	0,808 ± 0,012	0,949 ± 0,004	1,48 ± 0,15	626 ± 122	626 ± 122
■ UFLD v0.6 aligned	0,880 ± 0,011	0,957 ± 0,011	0,811 ± 0,009	0,949 ± 0,005	1,75 ± 0,11	626 ± 59	626 ± 59
■ UFLD v0.7 ConvGRU	0,895 ± 0,014	0,961 ± 0,011	0,816 ± 0,008	0,951 ± 0,004	1,63 ± 0,11	549 ± 75	549 ± 75
■ Lite baseline	0,218 ± 0,010	0,370 ± 0,000	0,408 ± 0,008	0,566 ± 0,019	1,77 ± 0,21	4078 ± 54	4078 ± 54
■ Lite baseline +CT	0,312 ± 0,061	0,482 ± 0,057	0,483 ± 0,056	0,663 ± 0,042	2,68 ± 0,12	3586 ± 317	3586 ± 317
■ Lite v0.5 warped	0,700 ± 0,012	0,899 ± 0,003	0,722 ± 0,000	0,903 ± 0,016	1,83 ± 0,04	1562 ± 62	1562 ± 62
■ Lite v0.6 ConvGRU	0,541 ± 0,011	0,754 ± 0,009	0,648 ± 0,002	0,814 ± 0,012	2,00 ± 0,01	2394 ± 56	2394 ± 56


Teste em cenas já vistas

MODELO	LANE F1 @0,5	LANE F1 @0,35	F1 DE PIXEL	F1 DE ÂNCORA	JITTER (PX)	FP	FN
■ UFLD baseline	0,849 ± 0,001	0,896 ± 0,013	0,807 ± 0,003	0,933 ± 0,005	2,01 ± 0,01	190 ± 1	190 ± 1
■ UFLD baseline +CT	0,847 ± 0,002	0,904 ± 0,003	0,810 ± 0,001	0,936 ± 0,000	2,36 ± 0,05	192 ± 3	192 ± 3
■ UFLD v0.2 weighted	0,845 ± 0,005	0,896 ± 0,005	0,810 ± 0,005	0,932 ± 0,005	1,88 ± 0,16	195 ± 6	195 ± 6
■ UFLD v0.3 gated	0,855 ± 0,007	0,902 ± 0,008	0,817 ± 0,008	0,935 ± 0,005	2,08 ± 0,07	182 ± 9	182 ± 9
■ UFLD v0.4 coord	0,841 ± 0,023	0,900 ± 0,015	0,810 ± 0,015	0,929 ± 0,008	1,93 ± 0,03	200 ± 28	200 ± 29
■ UFLD v0.6 aligned	0,850 ± 0,003	0,898 ± 0,003	0,814 ± 0,005	0,931 ± 0,003	2,40 ± 0,28	187 ± 4	189 ± 4
■ UFLD v0.7 ConvGRU	0,851 ± 0,002	0,899 ± 0,008	0,815 ± 0,008	0,934 ± 0,002	2,14 ± 0,19	188 ± 2	188 ± 2
■ Lite baseline	0,169 ± 0,014	0,438 ± 0,028	0,451 ± 0,012	0,648 ± 0,000	1,83 ± 0,29	1044 ± 17	1044 ± 17
■ Lite baseline +CT	0,389 ± 0,028	0,615 ± 0,004	0,567 ± 0,005	0,741 ± 0,010	2,61 ± 0,09	768 ± 35	768 ± 35
■ Lite v0.5 warped	0,793 ± 0,012	0,858 ± 0,004	0,738 ± 0,011	0,906 ± 0,003	2,07 ± 0,30	260 ± 16	260 ± 16
■ Lite v0.6 ConvGRU	0,685 ± 0,003	0,801 ± 0,021	0,694 ± 0,002	0,865 ± 0,003	2,02 ± 0,00	396 ± 4	396 ± 4

O contexto temporal ajuda?

Cada modelo temporal é comparado com o modelo de um quadro da sua família nas mesmas sementes (Wilcoxon exato, correção de Holm). Com 2 semente(s), nenhuma diferença pode alcançar $p < 0,05$; são precisas pelo menos 6 sementes, então os vereditos aqui são indicativos.


Modelo temporal menos a sua baseline de um quadro (lane F1 no teste)



Modelo Temporal	Comparado com	Sementes	Δ Lane F1	IC 95 %	P de Wilcoxon	P de Holm	Veredito
UFLD v0.2 weighted	UFLD baseline	2	-0,009	[-0,081, +0,063]	0,500	1,000	poucas sementes
UFLD v0.3 gated	UFLD baseline	2	+0,003	[-0,138, +0,143]	1,000	1,000	poucas sementes
UFLD v0.4 coord	UFLD baseline	2	-0,001	[-0,218, +0,216]	1,000	1,000	poucas sementes
UFLD v0.6 aligned	UFLD baseline	2	-0,001	[-0,110, +0,109]	1,000	1,000	poucas sementes
UFLD v0.7 ConvGRU	UFLD baseline	2	+0,014	[-0,123, +0,151]	0,500	1,000	poucas sementes
Lite v0.5 warped	Lite baseline	2	+0,483	[+0,283, +0,683]	0,500	1,000	poucas sementes
Lite v0.6 ConvGRU	Lite baseline	2	+0,323	[+0,133, +0,513]	0,500	1,000	poucas sementes

Controle com o mesmo treino

Os modelos temporais partem do melhor checkpoint da sua baseline e treinam mais. A baseline +CT recebe o mesmo treino extra; um ganho temporal que resiste a essa comparação não é efeito de mais épocas.



Modelo	Comparado com	Sementes	Δ Lane F1	IC 95 %	P de Wilcoxon	P de Holm	Veredito
UFLD v0.2 weighted	UFLD baseline +CT	2	-0,011	[-0,030, +0,007]	0,500	1,000	poucas sementes

MODELO	COMPARADO COM	SEMENTES	Δ LANE F1	IC 95 %	P DE WILCOXON	P DE HOLM	VEREDITO
UFLD v0.3 gated	UFLD baseline +CT	2	+0,000	[-0,086, +0,087]	1,000	1,000	poucas sementes
UFLD v0.4 coord	UFLD baseline +CT	2	-0,003	[-0,166, +0,160]	1,000	1,000	poucas sementes
UFLD v0.6 aligned	UFLD baseline +CT	2	-0,003	[-0,059, +0,053]	1,000	1,000	poucas sementes
UFLD v0.7 ConvGRU	UFLD baseline +CT	2	+0,012	[-0,071, +0,095]	0,500	1,000	poucas sementes
Lite v0.5 warped	Lite baseline +CT	2	+0,388	[-0,265, +1,042]	0,500	1,000	poucas sementes
Lite v0.6 ConvGRU	Lite baseline +CT	2	+0,229	[-0,415, +0,872]	0,500	1,000	poucas sementes
UFLD baseline +CT	UFLD baseline	2	+0,002	[-0,051, +0,056]	1,000	1,000	poucas sementes
Lite baseline +CT	Lite baseline	2	+0,094	[-0,359, +0,548]	0,500	1,000	poucas sementes

Contra o filtro de Kalman

As mesmas previsões filtradas pelo filtro de Kalman na saída (ajustado na validação). É o que o tempo dá quase de graça; um modelo temporal aprendido deveria superar a sua baseline + Kalman (tabela pareada abaixo).


MODELO	LANE F1	LANE F1 + KALMAN	JITTER (PX)	JITTER (PX) + KALMAN
■ UFLD baseline	0,881	0,881	1,51	1,19
■ UFLD baseline +CT	0,883	0,884	1,81	1,44
■ UFLD v0.2 weighted	0,872	0,874	1,45	1,19
■ UFLD v0.3 gated	0,883	0,883	1,58	1,25
■ UFLD v0.4 coord	0,880	0,880	1,48	1,20
■ UFLD v0.6 aligned	0,880	0,879	1,75	1,39
■ UFLD v0.7 ConvGRU	0,895	0,894	1,63	1,31
■ Lite baseline	0,218	0,215	1,77	1,26
■ Lite baseline +CT	0,312	0,309	2,68	2,11
■ Lite v0.5 warped	0,700	0,700	1,83	1,46
■ Lite v0.6 ConvGRU	0,541	0,540	2,00	1,57

MODELO TEMPORAL	COMPARADO COM	SEMENTES	Δ LANE F1	IC 95 %	P DE WILCOXON	P DE HOLM	VEREDITO
UFLD v0.2 weighted	UFLD baseline + Kalman	2	-0,010	[-0,089, +0,069]	0,500	1,000	poucas sementes
UFLD v0.3 gated	UFLD baseline + Kalman	2	+0,002	[-0,146, +0,149]	1,000	1,000	poucas sementes
UFLD v0.4 coord	UFLD baseline + Kalman	2	-0,002	[-0,226, +0,223]	1,000	1,000	poucas sementes
UFLD v0.6 aligned	UFLD baseline + Kalman	2	-0,002	[-0,119, +0,115]	1,000	1,000	poucas sementes
UFLD v0.7 ConvGRU	UFLD baseline + Kalman	2	+0,013	[-0,131, +0,157]	0,500	1,000	poucas sementes
Lite v0.5 warped	Lite baseline + Kalman	2	+0,486	[+0,321, +0,650]	0,500	1,000	poucas sementes
Lite v0.6 ConvGRU	Lite baseline + Kalman	2	+0,326	[+0,171, +0,481]	0,500	1,000	poucas sementes

Quando o quadro atual está degradado

As mesmas cenas de teste, mas todo quadro atual é corrompido (um retângulo cobrindo a imagem, desfoque forte, escurecimento ou ruído; a mesma corrupção para todos os modelos) enquanto os anteriores ficam limpos. É aqui que os quadros anteriores deveriam compensar: um modelo de um quadro só vê a imagem danificada. Pós-processamento ajustado na validação, nada reajustado.

Lane F1 no teste com o quadro atual degradado



MODELO	LIMPO	DEGRADADO	OCCLUSÃO	DESFOQUE	ESCURECIMENTO	RUÍDO	DEGRADADO + KALMAN
UFLD baseline	0,881	0,850	0,761	0,891	0,869	0,884	0,852
UFLD baseline +CT	0,883	0,849	0,742	0,894	0,873	0,891	0,850
UFLD v0.2 weighted	0,872	0,847	0,756	0,901	0,859	0,878	0,846
UFLD v0.3 gated	0,883	0,886	0,875	0,902	0,872	0,893	0,888
UFLD v0.4 coord	0,880	0,855	0,765	0,899	0,874	0,885	0,850
UFLD v0.6 aligned	0,880	0,884	0,864	0,907	0,874	0,890	0,886
UFLD v0.7 ConvGRU	0,895	0,874	0,802	0,915	0,883	0,899	0,873
Lite baseline	0,218	0,163	0,147	0,188	0,150	0,169	0,179
Lite baseline +CT	0,312	0,243	0,231	0,259	0,233	0,250	0,261
Lite v0.5 warped	0,700	0,679	0,670	0,702	0,671	0,673	0,680
Lite v0.6 ConvGRU	0,541	0,520	0,535	0,525	0,523	0,498	0,522

Modelos recorrentes com estado contínuo

Lane F1 no teste quando a ConvGRU mantém um estado por sequência ao longo da cena inteira, menos o modo de janela usado no treino (estado zero a cada clipe).

MODELO	CONTÍNUO - JANELA	SEMENTES
Lite v0.6 ConvGRU	-0,4832	2
UFLD v0.7 ConvGRU	-0,0280	2

É o histórico?

Ablação no teste: quadros do histórico trocados pelo quadro atual. O ganho é o que o histórico real contribui para cada modelo treinado.

MODELO TEMPORAL	GANHO DE F1 COM O HISTÓRICO REAL	SEMENTES
Lite v0.5 warped	+0,0200	2
Lite v0.6 ConvGRU	+0,0173	2

MODELO TEMPORAL	GANHO DE F1 COM O HISTÓRICO REAL	SEMENTES
UFLD v0.2 weighted	+0,0006	2
UFLD v0.3 gated	+0,0121	2
UFLD v0.4 coord	+0,0033	2
UFLD v0.6 aligned	+0,0076	2
UFLD v0.7 ConvGRU	+0,0049	2

Onde a informação temporal deveria ajudar


Lane F1 no teste por condição de cena, segundo as marcações de cena do ELAS (cenas inteiras, portanto três cenas, não subconjuntos de quadros), e jitter, a variação média da posição prevista da faixa entre quadros (menor é mais estável; inclui também o movimento real da faixa).

MODELO	OCCLUSÃO	TRANSIÇÃO	JITTER (PX)
■ UFLD baseline	0,741	0,948	1,51
■ UFLD baseline +CT	0,772	0,937	1,81
■ UFLD v0.2 weighted	0,742	0,934	1,45
■ UFLD v0.3 gated	0,771	0,938	1,58
■ UFLD v0.4 coord	0,766	0,935	1,48
■ UFLD v0.6 aligned	0,760	0,938	1,75
■ UFLD v0.7 ConvGRU	0,791	0,945	1,63
■ Lite baseline	0,060	0,294	1,77
■ Lite baseline +CT	0,119	0,405	2,68
■ Lite v0.5 warped	0,435	0,829	1,83
■ Lite v0.6 ConvGRU	0,250	0,681	2,00

A família lite com orçamento maior

Família lite, receita da v0.4, até 16 épocas (paciência 4), 2 sementes, sem busca de hiperparâmetros. Apenas indicativo.

Frente a frente nas estradas de teste



Mesma divisão, receita e avaliação; os números entre parênteses são as épocas máximas de cada execução (a parada antecipada pode terminar antes). Os modelos lite vêm de elas_lite_long, os demais de elas_pilot_v2.

Cenas de teste (média ± desvio padrão entre sementes)

MODELO	LANE F1 @0,5	LANE F1 @0,35	F1 DE PIXEL	F1 DE ÂNCORA	JITTER (PX)	FP	FN
■ Lite baseline	0,322 ± 0,018	0,518 ± 0,025	0,497 ± 0,009	0,676 ± 0,007	2,83 ± 0,23	3532 ± 94	3532 ± 94
■ Lite baseline +CT	0,322 ± 0,020	0,519 ± 0,027	0,506 ± 0,003	0,674 ± 0,006	3,32 ± 0,30	3534 ± 105	3534 ± 105
■ Lite v0.5 warped	0,850 ± 0,009	0,935 ± 0,013	0,788 ± 0,009	0,940 ± 0,011	2,19 ± 0,08	782 ± 47	782 ± 47
■ Lite v0.5 static	0,752 ± 0,177	0,876 ± 0,116	0,735 ± 0,074	0,899 ± 0,065	2,89 ± 0,63	1292 ± 923	1292 ± 923
■ Lite v0.6 ConvGRU	0,561 ± 0,027	0,726 ± 0,037	0,646 ± 0,015	0,811 ± 0,001	2,59 ± 0,32	2286 ± 141	2286 ± 141

Modelo temporal menos a sua baseline de um quadro (lane F1 no teste)



MODELO TEMPORAL	COMPARADO COM	SEMENTES	Δ LANE F1	IC 95 %	P DE WILCOXON	P DE HOLM	VEREDITO
Lite v0.5 warped	Lite baseline	2	+0,528	[+0,446, +0,609]	0,500	1,000	poucas sementes
Lite v0.6 ConvGRU	Lite baseline	2	+0,239	[-0,167, +0,645]	0,500	1,000	poucas sementes

Controle com o mesmo treino

Os modelos temporais partem do melhor checkpoint da sua baseline e treinam mais. A baseline +CT recebe o mesmo treino extra; um ganho temporal que resiste a essa comparação não é efeito de mais épocas.



MODELO	COMPARADO COM	SEMENTES	Δ LANE F1	IC 95 %	P DE WILCOXON	P DE HOLM	VEREDITO
Lite v0.5 warped	Lite baseline +CT	2	+0,528	[+0,427, +0,629]	0,500	1,000	poucas sementes
Lite v0.6 ConvGRU	Lite baseline +CT	2	+0,239	[-0,186, +0,665]	0,500	1,000	poucas sementes
Lite baseline +CT	Lite baseline	2	-0,000	[-0,020, +0,019]	1,000	1,000	poucas sementes

Controle de capacidade: camadas extras ou quadros anteriores?

O lite v0.5 static é o lite v0.5 com todo quadro do histórico trocado pelo quadro atual, no treino e no teste: mesmas camadas, inicialização e orçamento, mas sem informação temporal. "Lite v0.5 – static" é o que os quadros anteriores acrescentam; "static – baseline" é o que as camadas extras de fusão acrescentam sozinhas.



MODELO	COMPARADO COM	SEMENTES	Δ LANE F1	IC 95 %	P DE WILCOXON	P DE HOLM	VEREDITO
Lite v0.5 static	Lite baseline	2	+0,430	[-1,324, +2,184]	0,500	1,000	poucas sementes
Lite v0.5 warped	Lite v0.5 static	2	+0,098	[-1,575, +1,770]	1,000	1,000	poucas sementes

Contra o filtro de Kalman


As mesmas previsões filtradas pelo filtro de Kalman na saída (ajustado na validação). É o que o tempo dá quase de graça; um modelo temporal aprendido deveria superar a sua baseline + Kalman (tabela pareada abaixo).

MODELO	LANE F1	LANE F1 + KALMAN	JITTER (PX)	JITTER (PX) + KALMAN
■ Lite baseline	0,322	0,321	2,83	1,94
■ Lite baseline +CT	0,322	0,322	3,32	1,87
■ Lite v0.5 warped	0,850	0,847	2,19	1,74
■ Lite v0.5 static	0,752	0,750	2,89	2,31
■ Lite v0.6 ConvGRU	0,561	0,558	2,59	1,97

MODELO TEMPORAL	COMPARADO COM	SEMENTES	Δ LANE F1	IC 95 %	P DE WILCOXON	P DE HOLM	VEREDITO
Lite v0.5 warped	Lite baseline + Kalman	2	+0,529	[+0,434, +0,624]	0,500	1,000	poucas sementes
Lite v0.5 static	Lite baseline + Kalman	2	+0,432	[-1,336, +2,199]	0,500	1,000	poucas sementes
Lite v0.6 ConvGRU	Lite baseline + Kalman	2	+0,241	[-0,179, +0,660]	0,500	1,000	poucas sementes

Quando o quadro atual está degradado

As mesmas cenas de teste, mas todo quadro atual é corrompido (um retângulo cobrindo a imagem, desfoque forte, escurecimento ou ruído; a mesma corrupção para todos os modelos) enquanto os anteriores ficam limpos. É aqui que os quadros anteriores deveriam compensar: um modelo de um quadro só vê a imagem danificada. Pós-processamento ajustado na validação, nada reajustado.



MODELO	LIMPO	DEGRADADO	OCCLUSÃO	DESFOQUE	ESCURECIMENTO	RUÍDO	DEGRADADO + KALMAN
Lite baseline	0,322	0,261	0,254	0,258	0,263	0,268	0,277
Lite baseline +CT	0,322	0,271	0,258	0,270	0,287	0,272	0,287
Lite v0.5 warped	0,850	0,842	0,829	0,866	0,836	0,838	0,840
Lite v0.5 static	0,752	0,679	0,554	0,731	0,741	0,697	0,688
Lite v0.6 ConvGRU	0,561	0,563	0,554	0,560	0,591	0,547	0,561

Modelos recorrentes com estado contínuo

Lane F1 no teste quando a ConvGRU mantém um estado por sequência ao longo da cena inteira, menos o modo de janela usado no treino (estado zero a cada clipe).

MODELO	CONTÍNUO - JANELA	SEMENTES
Lite v0.6 ConvGRU	-0,1540	2

É o histórico?


Ablação no teste: quadros do histórico trocados pelo quadro atual. O ganho é o que o histórico real contribui para cada modelo treinado.

MODELO	TEMPORAL	GANHO DE F1 COM O HISTÓRICO REAL	SEMENTES
Lite v0.5 warped		+0,0042	2
Lite v0.6 ConvGRU		+0,0086	2

Corrigindo o overfitting da UFLD

O primeiro piloto mostrou toda execução da UFLD com o melhor resultado na época 1. Cada braço abaixo muda uma coisa no treino da UFLD baseline (mesma divisão, sementes, épocas e avaliação) e é comparado com a receita original (aumento fotométrico). A receita das execuções seguintes é escolhida pela coluna de validação; a coluna de teste é apenas relatada, nunca usada para escolher. "Melhores épocas" são as épocas escolhidas na validação em cada semente; o braço "mais cenas" tem o seu próprio conjunto de validação, maior. Três sementes não alcançam significância, então os vereditos são indicativos.



Lane F1 no teste por braço



BRAÇO	LANE F1 NA VALIDAÇÃO	LANE F1 NO TESTE	MELHORES ÉPOCAS	Δ NO TESTE × REFERÊNCIA
geométrico	0,772 ± 0,007	0,858 ± 0,002	4, 4, 4	+0,790 (poucas sementes)
geométrico + espelhamento	0,768 ± 0,001	0,769 ± 0,016	4, 4, 4	+0,701 (poucas sementes)
mais cenas (18)	0,288 ± 0,032	0,129 ± 0,023	1, 2, 2	+0,061 (poucas sementes)
cabeça pequena (256)	0,248 ± 0,026	0,210 ± 0,023	1, 1, 1	+0,142 (poucas sementes)
fotométrico estendido	0,175 ± 0,007	0,150 ± 0,016	1, 1, 1	+0,082 (poucas sementes)
stem + layer1 congelados	0,170 ± 0,021	0,083 ± 0,012	1, 1, 1	+0,015 (poucas sementes)
degradação do quadro atual	0,163 ± 0,020	0,094 ± 0,040	1, 1, 1	+0,026 (poucas sementes)
fotométrico	0,161 ± 0,034	0,068 ± 0,044	2, 2, 1	referência
nenhum	0,150 ± 0,022	0,068 ± 0,043	2, 1, 1	+0,000 (poucas sementes)
lr do backbone x0,1	0,149 ± 0,014	0,050 ± 0,004	1, 1, 1	-0,019 (poucas sementes)
regularizado	0,019 ± 0,023	0,002 ± 0,003	1, 1, 1	-0,066 (poucas sementes)







Até onde olhar para trás

Ablação do comprimento do histórico: todo braço usa a mesma divisão (intervalo de descarte grande o bastante para o histórico mais longo) e a mesma baseline treinada, então só o contexto temporal muda. As células são médias das sementes nas cenas de teste; braços "não rodados" podem ser adicionados com `ablate --only`.




Curvas de treino

Os modelos temporais e os controles +CT partem do melhor checkpoint da baseline da sua família.




■ UFLD v0.7 ConvGRU




lane F1 de validação por época; contínua = primeira semente, tracejada = segunda, ponto = melhor época (o checkpoint mantido)

■ Lite baseline




lane F1 de validação por época; contínua = primeira semente, tracejada = segunda, ponto = melhor época (o checkpoint mantido)

■ Lite baseline +CT




lane F1 de validação por época; contínua = primeira semente, tracejada = segunda, ponto = melhor época (o checkpoint mantido)

■ Lite v0.5 warped



lane F1 de validação por época; contínua = primeira semente, tracejada = segunda, ponto = melhor época (o checkpoint mantido)


■ Lite v0.6 ConvGRU



lane F1 de validação por época; contínua = primeira semente, tracejada = segunda, ponto = melhor época (o checkpoint mantido)

Latência e orçamentos de tempo real

Medido com lote 1 na NVIDIA GeForce RTX 3050, com quadros 640×480 do clipe de teste (checkpoints do primeiro piloto). \"em cache\" reaproveita as features guardadas dos quadros anteriores; \"recalculado\" codifica os três quadros toda vez. O pré-processamento (redimensionamento bilinear do PIL na CPU, igual ao do treino) é o maior custo.



Câmera simulada a 30 FPS: tempos de serviço = medido × fator de lentidão. Os fatores da Jetson são suposições a partir de razões de desempenho de pico, não medições numa Jetson. "Histórico substituído" são quadros cujo histórico foi pulado porque o processamento estava ocupado.

PERFIL	LENTIDÃO	MODELO	MODOS	FPS PROCESSADOS	LATÊNCIA P95 (MS)	HISTÓRICO SUBSTITUÍDO	ORÇAMENTOS
desktop	×1,0	UFLD baseline	quadro único	30,0	22,3	0 %	atendido
desktop	×1,0	UFLD v0.2 weighted	em cache	30,0	22,0	0 %	atendido
desktop	×1,0	UFLD v0.2 weighted	recalculado	30,0	30,1	0 %	atendido
desktop	×1,0	UFLD v0.3 gated	em cache	30,0	22,6	0 %	atendido
desktop	×1,0	UFLD v0.3 gated	recalculado	30,0	30,3	0 %	atendido
desktop	×1,0	UFLD v0.4 coord	em cache	30,0	21,7	0 %	atendido
desktop	×1,0	UFLD v0.4 coord	recalculado	30,0	38,5	0 %	atendido
desktop	×1,0	Lite baseline	quadro único	30,0	18,2	0 %	atendido
desktop	×1,0	Lite v0.5 warped	em cache	30,0	24,1	0 %	atendido
desktop	×1,0	Lite v0.5 warped	recalculado	30,0	33,7	0 %	atendido
jetson_agx_orin_assumed	×1,7	UFLD baseline	quadro único	29,0	50,4	0 %	não atendido

PERFIL	LENTIDÃO	MODELO	MODOS	FPS PROCESSADOS	LATÊNCIA P95 (MS)	HISTÓRICO SUBSTITUÍDO	ORÇAMENTOS
jetson_agx_orin_assumed	×1,7	UFLD v0.2 weighted	em cache	28,7	59,1	4 %	não atendido
jetson_agx_orin_assumed	×1,7	UFLD v0.2 weighted	recalculado	24,9	75,4	18 %	não atendido
jetson_agx_orin_assumed	×1,7	UFLD v0.3 gated	em cache	28,4	61,3	5 %	não atendido
jetson_agx_orin_assumed	×1,7	UFLD v0.3 gated	recalculado	24,2	77,2	21 %	não atendido
jetson_agx_orin_assumed	×1,7	UFLD v0.4 coord	em cache	29,0	51,6	3 %	não atendido
jetson_agx_orin_assumed	×1,7	UFLD v0.4 coord	recalculado	25,2	74,2	17 %	não atendido
jetson_agx_orin_assumed	×1,7	Lite baseline	quadro único	29,0	33,8	0 %	atendido
jetson_agx_orin_assumed	×1,7	Lite v0.5 warped	em cache	27,2	68,8	10 %	não atendido
jetson_agx_orin_assumed	×1,7	Lite v0.5 warped	recalculado	20,5	85,8	33 %	não atendido
jetson_orin_nano_assumed	×7,0	UFLD baseline	quadro único	7,8	186,5	0 %	não atendido
jetson_orin_nano_assumed	×7,0	UFLD v0.2 weighted	em cache	7,6	196,5	82 %	não atendido
jetson_orin_nano_assumed	×7,0	UFLD v0.2 weighted	recalculado	6,1	218,1	85 %	não atendido
jetson_orin_nano_assumed	×7,0	UFLD v0.3 gated	em cache	7,4	200,6	79 %	não atendido
jetson_orin_nano_assumed	×7,0	UFLD v0.3 gated	recalculado	5,8	228,7	92 %	não atendido
jetson_orin_nano_assumed	×7,0	UFLD v0.4 coord	em cache	7,5	202,6	79 %	não atendido
jetson_orin_nano_assumed	×7,0	UFLD v0.4 coord	recalculado	5,9	240,6	87 %	não atendido
jetson_orin_nano_assumed	×7,0	Lite baseline	quadro único	9,4	168,7	0 %	não atendido
jetson_orin_nano_assumed	×7,0	Lite v0.5 warped	em cache	7,7	199,3	80 %	não atendido
jetson_orin_nano_assumed	×7,0	Lite v0.5 warped	recalculado	5,8	243,9	87 %	não atendido

Exportação e verificação de precisão

Cada modelo exportado processa os mesmos quadros que o PyTorch pelo mesmo código de inferência contínua (checkpoints do primeiro piloto). O lane F1 de validação é medido em 240 quadros de validação com o mesmo contexto temporal do treino; a diferença para o PyTorch FP32 está entre parênteses. O TensorRT rodou na GPU de desenvolvimento, não numa Jetson.

MODELO	BACKEND	MÁX. Δ LOGITS	MÁX. Δ EXISTÊNCIA	ΔX MÉDIO DA FAIXA (PX)	LANE F1 (VAL.)	NUMÉRICA
Lite v0.5 warped	onnxruntime fp32	7,6e-06	3,6e-07	0,00	0,5636 (+0,0000)	dentro da tolerância
Lite v0.5 warped	onnxruntime int8	7,6e-06	6,4e-02	1,36	0,5570 (-0,0066)	fora da tolerância
Lite v0.5 warped	tensorrt fp32	1,8e-03	1,2e-04	0,00	0,5636 (+0,0000)	fora da tolerância
Lite v0.5 warped	tensorrt fp16	5,9e-02	1,3e-03	0,01	0,5636 (+0,0000)	fora da tolerância
Lite v0.5 warped	tensorrt int8	1,3e-02	2,1e-02	0,36	0,5658 (+0,0022)	fora da tolerância
UFLD baseline	onnxruntime fp32	2,4e-06	3,0e-07	0,00	0,1732 (+0,0000)	dentro da tolerância
UFLD baseline	onnxruntime int8	3,5e-01	3,6e-02	2,29	0,1776 (+0,0044)	fora da tolerância
UFLD baseline	tensorrt fp32	4,7e-04	6,4e-05	0,00	0,1732 (+0,0000)	dentro da tolerância
UFLD baseline	tensorrt fp16	8,7e-03	6,2e-04	0,02	0,1732 (+0,0000)	dentro da tolerância
UFLD baseline	tensorrt int8	1,7e-01	1,7e-02	0,54	0,1732 (+0,0000)	fora da tolerância
UFLD v0.2 weighted	onnxruntime fp32	1,4e-06	1,8e-07	0,00	0,0789 (+0,0000)	dentro da tolerância
UFLD v0.2 weighted	onnxruntime int8	1,4e-06	5,1e-03	0,72	0,0636 (-0,0154)	fora da tolerância
UFLD v0.2 weighted	tensorrt fp32	5,5e-04	2,5e-05	0,00	0,0789 (+0,0000)	dentro da tolerância
UFLD v0.2 weighted	tensorrt fp16	5,7e-03	3,7e-04	0,01	0,0789 (+0,0000)	dentro da tolerância
UFLD v0.2 weighted	tensorrt int8	6,9e-04	1,0e-02	0,41	0,0768 (-0,0022)	fora da tolerância


Exemplos das cenas de teste




UFLD baseline, teste, um acerto típico: original | anotação (verde) | previsão (vermelho) - VV_S03_786



UFLD baseline, teste, um erro típico: original | anotação (verde) | previsão (vermelho) - VIX_S05_52



UFLD v0.7 ConvGRU, teste, um acerto típico: original | anotação (verde) | previsão (vermelho) - VV_S03_775



UFLD v0.7 ConvGRU, teste, um erro típico: original | anotação (verde) | previsão (vermelho) - VIX_S05_51

Roteiro

Primeiro, fazer um modelo temporal leve superar a UFLD baseline no protocolo completo; só depois otimizar para um sistema embarcado no carro.

Fase 1: protocolo e primeiro piloto (v0.3)

feito

Protocolo do ELAS sem vazamento de dados: três cenas de estrada reservadas para teste, blocos de 60 quadros com intervalo de descarte, seis sementes, busca de hiperparâmetros com o mesmo orçamento para todos os modelos e seleção apenas na validação.

feito

Piloto na GPU (2 sementes, até 4 épocas): o lite v0.5 foi o melhor nas estradas nunca vistas; toda execução da UFLD atinge o melhor resultado na época 1 e depois sofre overfitting; o histórico acrescenta pouco a qualquer modelo.

feito

Ferramentas de implantação: ONNX, TensorRT FP32 / FP16 / INT8 na GPU do desktop e inferência contínua (streaming) com features do histórico em cache.

Fase 2: fazer um modelo temporal leve superar a UFLD baseline (v0.4)

feito

Corrigir o overfitting da UFLD: o aumento de dados geométrico leva a UFLD baseline de 0,07 para 0,86 de lane F1 no teste (configs/ablations/augmentation.yaml, escolhido na validação); aumento fotométrico estendido, espelhamento e dropout + label smoothing não ajudam.

feito

As outras alavancas contra o overfitting, cada uma como mudança única na receita original: taxa de aprendizado do backbone 10× menor, camadas iniciais congeladas, cabeça menor, degradação do quadro atual e 8 cenas a mais do ELAS. Nenhuma resolve o overfitting sozinha (lane F1 no teste de 0,05 a 0,21, melhor época ainda 1 ou 2); o aumento geométrico continua sendo a receita. A inicialização a partir de outra base (model.init_checkpoint) está implementada para quando houver pesos de CULane / TuSimple.

feito

Histórico mais longo (configs/ablations/history.yaml, UFLD v0.4, 4 braços): espaçamentos de 2, 5 e 10 quadros dão o mesmo ganho sobre a baseline (cerca de +0,03); 5 quadros em vez de 3 eliminam o ganho. Outros braços da grade (passos de 1 a 15, 2 a 5 quadros) podem ser adicionados com ablate --only.

feito

Degradação do quadro atual: só o quadro atual é ocluído, borrado, escurecido ou recebe ruído, enquanto o histórico fica limpo, para que o modelo temporal precise usar o histórico (data.augmentation.current_frame_prob).

feito

Alinhar antes de fundir: UFLD v0.6 (o warp e o gate aprendidos do lite v0.5 sobre as features da UFLD).

feito

Estado recorrente: UFLD v0.7 e lite v0.6 (ConvGRU); a inferência contínua pode manter um estado por câmera (--mode carry).

feito

Controles com o mesmo treino: as baselines +CT recebem o mesmo treino extra que os modelos temporais.

feito

Avaliar onde o tempo deve ajudar: lane F1 por condição de cena, jitter e um filtro de Kalman ajustado na validação como referência temporal barata.

feito

Segundo piloto com os modelos e a receita da v0.4 (configs/elas_pilot_v2.yaml): UFLD baseline 0,881, melhor UFLD temporal (v0.7) 0,895; os modelos lite precisam de mais épocas.

feito

Controle de capacidade lite_v05_static: lite v0.5 alimentado com o quadro atual em todas as posições, para separar o ganho temporal das camadas extras de fusão.

feito

Família lite com orçamento maior (até 16 épocas) e o controle de capacidade (configs/elas_lite_long.yaml): o lite v0.5 chega a 0,850 com 8× menos parâmetros que a UFLD; com o quadro atual ocluído, o histórico vale +0,17 e +0,38 sobre o controle sem histórico.

feito

Avaliação de robustez: quadro atual ocluído, borrado, escurecido ou com ruído e histórico limpo. Com oclusão, a UFLD v0.3 mantém 0,875 de lane F1 contra 0,761 da baseline, nas duas sementes.

próximo

Treinar os modelos recorrentes com sequências longas, para que um único estado contínuo por câmera funcione (o modo contínuo deriva após treino com 3 quadros).

Fase 3: protocolo completo (orientador)

próximo

Execução completa: 6 sementes, busca de hiperparâmetros, até 50 épocas, com a receita e os modelos escolhidos nos pilotos (`configs/elas.yaml`).

depois

Pré-treino em CULane / TuSimple e ajuste fino no ELAS (precisa das bases ou dos pesos oficiais da UFLD).

Fase 4: implantação embarcada automotiva (última etapa)

depois

Medir no dispositivo real: gerar os engines TensorRT em uma Jetson e rodar o script de medição; os números atuais da Jetson são simulações com fatores de lentidão assumidos.

depois

Tirar o pré-processamento da CPU: o redimensionamento na CPU leva cerca de 9 ms de um quadro de 14 a 19 ms. Redimensionar no processador de imagem da câmera ou na GPU com buffers sem cópia, e retreinar com esse mesmo redimensionamento.

depois

Recortar a estrada: as âncoras de linha cobrem só os 41 % inferiores da imagem, então o recorte reduz o custo em cerca de 2,4 vezes; uma resolução de entrada menor é a segunda opção. As duas exigem retreino.

depois

TensorRT FP16 por padrão (sem perda no piloto); INT8 só se o FP16 for lento demais, calibrado com a câmera do carro ou com treino ciente da quantização para os modelos lite.

depois

Preferir a família lite: cerca de 8 vezes menos parâmetros e 3,6 vezes menos computação que a UFLD.

depois

Robustez a quadros perdidos: treinar com quadros descartados e espaçar o histórico por tempo, pois a câmera do carro pode ter outra taxa de quadros que a do ELAS.

depois

Execução de produção: TensorRT em C++ ou DeepStream em vez de Python, captura / inferência / pós-processamento em paralelo, sempre processar o quadro mais recente, clocks fixos e testes térmicos dentro do invólucro.

Reproduzir e continuar

```
python -m tac_ufld doctor
python -m pytest -q
python -m tac_ufld ablate --spec configs/ablations/augmentation.yaml --confirm # overfitting remedies
python -m tac_ufld run --config configs/elas_pilot_v2.yaml # pilot with the v0.4 models
python -m tac_ufld ablate --spec configs/ablations/history.yaml --confirm # history length
python -m tac_ufld run --config configs/elas.yaml --confirm # full protocol
python -m tac_ufld ui # inspect checkpoints
python -m tac_ufld site --runs results/elas_pilot_v2 # rebuild this page
```

O experimento completo difere dos pilotos nas sementes (6 em vez de 2), nas épocas (até 50, com paciência 10) e na busca de hiperparâmetros (o mesmo orçamento para todos os modelos). Só a execução completa pode sustentar conclusões.

Gerado em 2026-09-30 a partir do git d4cae20 por `python -m tac_ufld site`. Os números vêm das pastas das execuções; os resultados comentados, o roteiro e as descrições dos modelos são escritos à mão.